Maschinelles Lernen 1:

1. Klausur WS18/19

4 multiple choice fragen: 20 Punkte 4 x 5

nur eine richtige antwort

What is not a discriminant function:

- a) $P(w_c|x)$
- $b)P(x|w_c)*P(w_c)$
- c) $P(w_c|x)*P(w_c)^{-1}$
- d) $P(x|w_c)^2*P(w_c)^2$

What is likely an overfitted estimator?

- a) High bias model
- b) High variance model
- c) Low bias model
- d) Low variance model

What does Fisher discriminant optimize?

- a)..
- b)...
- c) Maximize ratio Within class variance to between class variance
- d) Minimize ratio Within class variance to between class variance

What does the constant C stand for in SWM?

- a) ability of the decision boundary to be out of the margin
- b) number of points not being classified correctly
- c)
- d)

Boosting: 15 Punkte

Genau wie in der Hausaufgabe, Gewichte der Punkte und gewichte der Classifier angeben

Kernel: 20 Punkte 4 x 5

Genau wie in Hausaufgabe:

- a) Zeige das k_3 = alpha* k_1 + beta* k_2 wieder ein positive semidefiniter Kernel ist. Alpha, beta >= 0
- b) Zeige das wenn alpha oder beta < 0 , dass dann die obere bedingung nicht mehr stimmt.
- c) Find a mapping for k_3 asssuming that $k_2 = < Phi_2(x_i), Phi_2(x_j)>$, $k_1 = < Phi_1(x_i), Phi_1(x_j)>$ and prove that it satisfies $k_3 = < Phi_3(x_i), Phi_3(x_j)>$
- d) Do the same as in c but for $k4(x_i,x_j)=k3(x_i,x_i)k3(x_j,x_j)$

Kernel: 20 Punkte (4 × 5)

Genau wie in Hausaufgabe:

a)

Zeige, dass

$$k_3 = \alpha k_1 + \beta k_2$$

wieder ein positiv semidefiniter Kernel ist.

Voraussetzung: $\alpha, \beta \geq 0$.

b)

Zeige, dass wenn α oder $\beta < 0$, dann die obere Bedingung nicht mehr stimmt.

c)

Finde eine Mapping-Funktion für k_3 , unter der Annahme:

$$k_2 = \langle \Phi_2(x_i), \Phi_2(x_j)
angle, \quad k_1 = \langle \Phi_1(x_i), \Phi_1(x_j)
angle$$

und beweise, dass dies die Bedingung

$$k_3 = \langle \Phi_3(x_i), \Phi_3(x_j)
angle$$

erfüllt.

$$k_{3} = Q \cdot \mathcal{I}_{A}(x_{1}), \mathcal{I}_{A}(x_{1}) + \beta \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1})$$

$$= Q \cdot \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1}) + \beta \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1})$$

$$= [Q \cdot \mathcal{I}_{A}(x_{1}), Q \cdot \mathcal{I}_{A}(x_{1})] \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1})$$

$$= (Q \cdot \mathcal{I}_{A}(x_{1}), Q \cdot \mathcal{I}_{A}(x_{1})) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1})$$

$$= (Q \cdot \mathcal{I}_{A}(x_{1}), Q \cdot \mathcal{I}_{A}(x_{1})) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1})$$

$$= (Q \cdot \mathcal{I}_{A}(x_{1}), Q \cdot \mathcal{I}_{A}(x_{1})) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1})$$

$$= (Q \cdot \mathcal{I}_{A}(x_{1}), Q \cdot \mathcal{I}_{A}(x_{1})) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1})$$

$$= (Q \cdot \mathcal{I}_{A}(x_{1}), Q \cdot \mathcal{I}_{A}(x_{1})) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1})$$

$$= (Q \cdot \mathcal{I}_{A}(x_{1}), Q \cdot \mathcal{I}_{A}(x_{1})) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A}(x_{1})$$

$$= (Q \cdot \mathcal{I}_{A}(x_{1}), Q \cdot \mathcal{I}_{A}(x_{1})) \mathcal{I}_{A}(x_{1}) \mathcal{I}_{A$$

d)

Mache dasselbe wie in c, aber für

$$k_4(x_i,x_j)=k_3(x_i,x_i)k_3(x_j,x_j)$$

$$= \phi_{3}(X_{A})^{T} \phi_{3}(X_{A}) \phi_{4}(X_{2})^{T} \phi_{3}(X_{2})$$

$$= (\phi_{3}(X_{A})^{T} \phi_{4}(X_{A}))^{T} \phi_{3}(X_{2})^{T} \phi_{3}(X_{2})$$

$$= \phi_{4}$$

Lagrang: 25 Punkte 5 x 5

Sigma is the covariance matrix of the dataset max
$$w w^T$$
 s.t. $w Sigma^{-1} w^T = 1$

max w w^T s.t. w Sigma⁻¹ w^T = 1
$$\sum w = \lambda W$$
a) Derive Lagrangian
$$L = WW^{T} - \lambda (W \sum^{-\Lambda} W^{T} - \Lambda)$$

 $\frac{3N}{3\Gamma} = 3N - 3y_2 = 0$ $\frac{3N}{3\Gamma} = 3N - 3y_2 = 0$

- b) Show that the problem is a Eigenvalue problem of Sigma.
- c) Show that the solution is the eigenvector corresponding to the largest eigenvalue.

e) What algorith does this look similar to regarding PCA mentioned in ML1?

Regression: 20 Punkte 5, 15

Klassisches Regressionsproblem:

min Summe
$$(y_i - wx_i + b)^2$$
 oder so.

- a) Zeigen das min w^TXXw 2yXw das gleiche problem ist.
- b) Erstelle die Matrixen wie in der hausaufgabe für diesen gudratic solver. Q,b,A,l Da war auch noch eine Konstante C gegeben.